

Derin Öğrenme Tabanlı 8 Sınıflı Araba Gövde Tipi Sınıflandırma: EfficientNet-B0 ile Transfer Öğrenme Yaklaşımı

Burak Kılıcı
Bilgisayar Mühendisliği Bölümü
Kocaeli Üniversitesi
Kocaeli, Türkiye
230202111@kocaeli.edu.tr

Özet—Bu çalışmada, sekiz farklı araba gövde tipini (SUV, Van, Station Wagon, Micro, Açık Tekerlekli, Sedan, Hatchback, Pick-up) görsel girdiden otomatik olarak sınıflandıran bir derin öğrenme modeli geliştirilmiştir. Kaggle veri setlerinden ve web arama motorlarından toplanan toplam 6628 görsel ile özelleştirilmiş bir veri seti oluşturulmuş, ImageNet üzerinde ön-eğitilmiş EfficientNet-B0 mimarisi transfer öğrenme yaklaşımıyla yeniden eğitilmiştir. Eğitim sürecinde altı farklı veri çoğaltma tekniği, etiket yumuşatma (label smoothing), sınıf ağırlıklandırması, ayrımcı öğrenme oranı stratejisi, cosine annealing planlayıcısı ve erken durdurma mekanizması bir arada uygulanarak modelin genelleme kapasitesi artırılmıştır. 30 epoch süren eğitim sonunda test setinde elde edilen makro ortalama F1 skoru 0.8714, ağırlıklı F1 skoru 0.8726 ve doğruluk (accuracy) %87.41 olarak ölçülmüştür. Sınıf bazında değerlendirildiğinde Açık Tekerlekli (F1) sınıfı için mükemmel ayrım ($F1=1.0000$), Van için 0.9720, Micro için 0.9444 gibi yüksek skorlar elde edilmiştir. Eğitilen model, Streamlit tabanlı bir web arayüzüne entegre edilmiş; NVIDIA RTX 2060 GPU üzerinde, önbellek ısıdıktan sonra ortalama 62 ms gibi düşük bir çıkarım süresiyle canlı tahmin yapabilmektedir. Toplam model boyutu 95 MB sınırının çok altında (~20 MB) tutulmuştur.

Anahtar Kelimeler—derin öğrenme, evrimsel sinir ağları, transfer öğrenme, EfficientNet, görüntü sınıflandırma, araba gövde tipi, veri çoğaltma, sınıf dengesizliği

I. GİRİŞ

A RAÇ türünün görüntüden otomatik tanınması; otonom sürüş, akıllı trafik analizi, sigorta hasar tespiti, akıllı park sistemleri ve trafik denetim altyapıları gibi pek çok uygulama alanında kritik bir bileşendir [1]. Klasik bilgisayarlı görüş yaklaşımları (HoG, SIFT gibi el yapımı öznitelikler) bu problemde sınırlı başarı gösterirken, son yıllarda evrimsel sinir ağları (CNN) ve transformatör tabanlı mimariler büyük ölçekli görüntü sınıflandırma problemlerinde insan-üstü performansa ulaşmıştır.

Bu çalışmada ele alınan problem, sekiz sınıflı bir görüntü sınıflandırma görevidir. Sınıflar şunlardır: SUV, Van, Station Wagon, Micro, Açık Tekerlekli (F1 yarış araçları), Sedan, Hatchback ve Pick-up. Problemi zorlaştıran üç temel etken bulunmaktadır:

- **Sınıflar arası görsel benzerlik:** Sedan ile Hatchback, Station Wagon ile Hatchback gibi sınıflar geometrik

açıdan birbirine çok yakındır; sınırlar bazen sürekli bir spektruma yayılmıştır.

- **Sınıf-içi yüksek varyans:** Aynı sınıf içinde farklı marka, model, yıl, renk, açı ve ışık koşulları bulunmaktadır.
- **Sınıf dengesizliği:** Bazı sınıflar (örn. Micro, Station Wagon) için açık veri kaynaklarında daha az görsel mevcuttur.

Bu çalışmanın temel katkıları aşağıdaki gibi özetlenebilir:

- Kaggle veri setleri ve web arama motorlarından derlenen görsellerle dengeli ve çeşitli bir özelleştirilmiş veri seti oluşturulması; toplam 6628 görselin sekiz sınıfa elle ayıklanarak dağıtılması.
- Transfer öğrenme yaklaşımıyla, model boyutunu 95 MB sınırının çok altında tutarken yüksek doğruluk sağlayan EfficientNet-B0 tabanlı bir mimarinin eğitilmesi.
- Sınıf dengesizliğine karşı sınıf ağırlıklandırması, agresif veri çoğaltma ve etiket yumuşatma gibi tekniklerin entegre kullanımı.
- Eğitilen modelin canlı tahmin yapabildiği, kullanıcı dostu bir Streamlit web arayüzünün geliştirilmesi ve uçtan uca test edilmesi.

Raporun kalan kısmı şöyle düzenlenmiştir: Bölüm II ilgili çalışmaları özetler; Bölüm III veri setinin hazırlanışını detaylandırır; Bölüm IV kullanılan model mimarisini ve eğitim ayrıntılarını sunar; Bölüm V deneysel sonuçları ve hata analizini sergiler; Bölüm VI web arayüzünü tanıtır ve Bölüm VII sonuçları özetleyip gelecek çalışmaları tartışır.

II. İLGİLİ ÇALIŞMALAR

Görüntüden araç sınıflandırma problemi literatürde uzun bir geçmişe sahiptir. Krause ve diğerleri [1], 3D nesne temsilleri kullanarak ince taneli araç sınıflandırması üzerine çalışmış ve 196 farklı araç modelinden oluşan Stanford Cars veri setini yayımlamıştır.

CNN tabanlı mimariler arasında VGG, ResNet ve Inception aileleri uzun süre baskın olmuştur. Tan ve Le [2], derinlik, genişlik ve çözünürlüğü tek bir bileşik katsayı (*compound coefficient*) ile dengeli şekilde ölçekleyen **EfficientNet** ailesini önermiş; aynı parametre bütçesinde önceki mimarilere kıyasla

belirgin doğruluk artışı sağlamıştır. EfficientNet-B0, sadece 5.3 milyon parametre içerirken ImageNet üzerinde %77.3 top-1 doğruluk elde etmektedir; bu, projemizin 95 MB sınırına ve performans hedeflerine ideal bir uyum sağlamaktadır.

Transfer öğrenme, sınırlı veriyle eğitim yapan çalışmalarda standart yaklaşım hâline gelmiştir. ImageNet üzerinde ön-eğitilmiş ağırlıkların fine-tuning’i, sıfırdan eğitime kıyasla hem hız hem de doğruluk avantajı sağlar.

Sınıf dengesizliği probleminin ele alınmasında çeşitli yaklaşımlar mevcuttur: yeniden örnekleme, sınıf ağırlıklı kayıp fonksiyonları ve SMOTE benzeri sentetik veri üretimi. Çalışmamızda hesaplama maliyeti açısından en uygun olan sınıf ağırlıklı Cross-Entropy yaklaşımı tercih edilmiştir. Aşırı güvenli (overconfident) tahminleri azaltmak için Szegedy ve diğerlerinin önerdiği **label smoothing** tekniği uygulanmıştır [3].

III. VERİ SETİ

A. Veri Kaynakları

Veri seti, çeşitliliği maksimuma çıkarmak ve aşırı uyumu (overfitting) engellemek amacıyla birden fazla kaynaktan derlenmiştir:

- 1) **Car Body Types Images Dataset** [7]: Kaggle üzerindeki bu set; Convertible, Coupe, Hatchback, Pick-Up, SUV, Sedan ve Van olmak üzere 7 sınıftan ve sınıf başına yaklaşık 1000 görselden oluşmaktadır. Çalışmamızdaki 8 sınıfla örtüşen 5 sınıf (Hatchback, Pick-Up, SUV, Sedan, Van) bu kaynaktan alınmıştır.
- 2) **Stanford Car Body Type Data** [8]: Stanford Cars veri setinin gövde tipi alt etiketlemesi sayesinde Wagon kategorisi STATION_WAGON sınıfımıza dahil edilmiştir.
- 3) **F1 Image Classification Dataset** [9]: Formula 1 takım bazlı görseller içeren bu set, Açık Tekerlekli sınıfının veri kaynağıdır. 10 takıma ait görsel tek bir klasörde birleştirilmiştir; çünkü problemimizde takım kimliği değil, aracın açık tekerlekli olma özelliği önemlidir.
- 4) **Web Görselleri**: Micro sınıfı için Kaggle’da uygun bir veri seti bulunamadığından, Google Images üzerinden “Citroen Ami”, “Smart Fortwo”, “Renault Twizy”, “Microlino” ve “Aixam microcar” arama terimleri kullanılarak manuel toplama yapılmıştır. Toplanan her görsel alakasız/render/insan baskın gibi kriterlere göre elle ayıklanmıştır.

Sınıf dağılımı tek bir kaynağa aşırı bağımlı olmasın diye Açık Tekerlekli sınıfı 4063 görselden 800’e indirilmiş; böylece sınıflar arası oran daha dengeli hâle getirilmiştir.

B. Veri Bölünmesi

Toplanan veri seti rastgele (sabit $t_{\text{ohum}}=42$ ile tekrarlanabilir şekilde) %75 eğitim, %15 doğrulama ve %10 dahili test olarak bölünmüştür. Bölme işlemi sınıf bazında yapılmış, böylece her bölüm tüm sınıfların orantılı dağılımını korumaktadır. Sınıf başına bölüm sayıları Tablo I’de sunulmuştur.

Tablo I
VERİ SETİ DAĞILIMI (SINIF BAŞINA GÖRSEL SAYISI)

Sınıf	Eğitim	Doğr.	Test	Top.
SUV	936	186	124	1246
Van	788	157	105	1050
Station Wagon	219	43	29	291
Micro	139	27	18	184
Açık Tekerlekli	591	118	78	787
Sedan	757	151	100	1008
Hatchback	733	146	97	976
Pick-up	816	162	108	1086
Toplam	4979	990	659	6628

C. Ön İşleme

Tüm görseller, EfficientNet-B0’nın doğal giriş boyutu olan 224×224 piksele dönüştürülmüştür. Görselin kısa kenarı önce 256 piksele yeniden boyutlandırılmış ($\text{Resize}(256)$), ardından merkezden 224×224 piksel kırılmıştır ($\text{CenterCrop}(224)$). Piksel değerleri $[0, 1]$ aralığına ölçeklendikten sonra ImageNet istatistikleri ($\mu = (0.485, 0.456, 0.406)$, $\sigma = (0.229, 0.224, 0.225)$) ile normalize edilmiştir.

D. Veri Çoğaltma

Eğitim setinin etkin boyutunu artırmak ve modelin genelleme yeteneğini güçlendirmek için altı farklı çoğaltma tekniği birleştirilmiştir; bu teknikler yalnızca eğitim setine uygulanmıştır:

- **RandomResizedCrop** (scale = 0.7–1.0): Konum ve ölçek invaryansı kazandırır.
- **RandomHorizontalFlip** ($p = 0.5$): Arabaların yansıma simetrisine sahip olması nedeniyle güvenle kullanılabilen, etkili bir çoğaltmadır.
- **RandomRotation** ($\pm 15^\circ$): Kameranın eğri tutulduğu durumları simüle eder.
- **ColorJitter**: Farklı ışık koşullarına karşı dayanıklılık sağlar.
- **RandomPerspective** ($p = 0.3$): Aracın farklı açılardan görünümünü taklit eder.
- **RandomErasing** ($p = 0.25$): Modeli aracın tamamına bakmaya zorlar, küçük bir detaya aşırı bağlanmasını önler.

IV. YÖNTEM

A. Mimari Seçimi

Sınıflandırıcı omurga olarak **EfficientNet-B0** [2] seçilmiştir. Bu seçimin başlıca gerekçeleri şunlardır:

- **Boyut verimliliği**: ~20 MB state-dict; proje şartı olan 95 MB sınırının çok altında.
- **Compound scaling**: Derinlik, genişlik ve çözünürlüğün dengeli ölçeklenmesi, aynı parametre bütçesinde ResNet-50, VGG-16 gibi klasik mimarilere kıyasla belirgin doğruluk artışı sağlamaktadır.

- **MBCConv blokları:** Squeeze-and-Excitation (SE) modülü içeren ters-bottleneck yapısı, parametre başına ifade gücünü artırır.
- **Hızlı çıkarım:** RTX 2060 üzerinde, önbellek devreye girdikten sonra tek görüntü tahmini ~62 ms.

B. Mimari Uyarlaması

Orijinal EfficientNet-B0'ın son sınıflandırıcı katmanı Linear(1280 → 1000) şeklinde olup ImageNet'in 1000 sınıfını tahmin eder. Bu katman projemizin 8 sınıfına uyacak şekilde aşağıdaki gibi değiştirilmiştir:

$$\text{classifier} = \text{Dropout}(p=0.3) \rightarrow \text{Linear}(1280 \rightarrow 8)$$

Tüm katmanlar geriye yayılıma açık tutulmuş (full fine-tuning); ancak ayrımcı öğrenme oranı (*discriminative learning rates*) stratejisi uygulanmıştır:

$$\eta_{\text{backbone}} = 10^{-4}, \quad \eta_{\text{head}} = 10^{-3}$$

Bu stratejinin gerekçesi: backbone, ImageNet üzerinde milyonlarca görselden öğrenilmiş zengin özellikler içerir ve agresif güncellemeler bu bilgiyi bozar. Sınıflandırıcı baş ise rastgele başlatıldığından hızlı öğrenme için daha yüksek bir öğrenme oranı ister.

C. Kayıp Fonksiyonu

Çoklu sınıflandırma için ağırlıklı Cross-Entropy kaybı kullanılmıştır:

$$\mathcal{L} = - \sum_{i=1}^C w_i \cdot y_i^{\text{LS}} \log \hat{p}_i$$

Etiket yumuşatma (label smoothing, $\epsilon = 0.1$) formülü:

$$y_i^{\text{LS}} = (1 - \epsilon)y_i + \frac{\epsilon}{C}$$

Bu, aşırı güvenli softmax çıktıları engeller ve genellemeyi artırır. Sınıf ağırlıkları frekansla ters orantılı olarak $w_i = N/(C \cdot n_i)$ şeklinde hesaplanmıştır. Hesaplanan ağırlıklar Tablo II'de sunulmuştur; Micro sınıfı 4.48 ağırlık olarak az veri probleminin etkisi azaltılmıştır.

Tablo II
HESAPLANAN SINIF AĞIRLIKLARI

Sınıf	Ağırlık
SUV	0.66
Van	0.79
Station Wagon	2.84
Micro	4.48
Açık Tekerlekli	1.05
Sedan	0.82
Hatchback	0.85
Pick-up	0.76

D. Optimizasyon

AdamW [4] ($\beta_1=0.9$, $\beta_2=0.999$, weight decay = 10^{-4}) optimizasyon algoritması seçilmiştir. AdamW, klasik Adam'a kıyasla L2 düzenleme oranını doğru şekilde uygular ve transfer öğrenmede daha kararlı sonuçlar verir.

Öğrenme oranı planlayıcısı olarak **Cosine Annealing** kullanılmış; öğrenme oranı başlangıç değerinden 10^{-6} 'a kadar yumuşakça düşürülmüştür:

$$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_{\max} - \eta_{\min})(1 + \cos(\frac{t}{T}\pi))$$

E. Hiperparametreler ve Erken Durdurma

Tüm hiperparametreler Tablo III'de özetlenmiştir. Batch boyutu başlangıçta 32 olarak denenmiş; ancak RTX 2060'ın 6 GB VRAM'ı yetersiz kaldığı için 16'ya düşürülmüştür.

Doğrulama kaybının 7 ardışık epoch boyunca iyileşmemesi durumunda eğitim otomatik olarak sonlandırılır. Eğitim süresince yalnızca en düşük doğrulama kaybına sahip ağırlıklar diske kaydedilir.

Tablo III
EĞİTİM HIPERPARAMETRELERİ

Parametre	Değer
Batch boyutu	16
Maksimum epoch sayısı	30
Backbone öğrenme oranı	10^{-4}
Baş öğrenme oranı	10^{-3}
Weight decay	10^{-4}
Dropout	0.3
Label smoothing	0.1
Erken durdurma sabrı	7 epoch
Görsel boyutu	224×224
Veri yükleyici işçi say.	0 (Windows uyumluluğu)
Sabit tohum	42

V. DENEYSEL SONUÇLAR


A. Donanım ve Yazılım

Eğitim ve değerlendirme NVIDIA GeForce RTX 2060 (6 GB VRAM) GPU üzerinde gerçekleştirilmiştir. Yazılım yığını: Python 3.11, PyTorch 2.7.1 (CUDA 11.8), torchvision 0.22, scikit-learn ve Streamlit. Eğitim süresi 30 epoch için yaklaşık 70 dakika sürmüştür (batch boyut=16, ortalama 2.5 it/s).


B. Eğitim Süreci

Eğitim ve doğrulama kayıp eğrileri Şekil 1'de, doğruluk eğrileri Şekil 2'da gösterilmiştir.

Eğitim doğruluğu 30. epoch'ta %99.3'e ulaşırken doğrulama doğruluğu %86.1'de durulmuştur. Bu boşluk (~13 puan) kontrolsüz overfitting işareti değildir; doğrulama doğruluğu sürekli artış eğilimi göstermiş ve platoya ulaşmıştır. Erken durdurma mekanizması 30 epoch boyunca tetiklenmemiş; yani model son epoch'a kadar iyileşmeye devam etmiştir. En düşük doğrulama kaybı 23. epoch'ta 1.0349 olarak kaydedilmiş ve son modelin temeli bu olmuştur.



Şekil 1. Eğitim ve doğrulama kayıp eğrileri. Her iki eğri de düşüş göstermiş, aralarındaki boşluk kontrol altında kalmıştır.



Şekil 2. Eğitim ve doğrulama doğruluk eğrileri. Doğrulama doğruluğu 1. epoch'ta %75.6 ile başlamış, 30. epoch'ta %86.1'e ulaşmıştır.

C. Test Performansı

Test setinde elde edilen sınıf bazlı ve ortalama metrikler Tablo IV'de sunulmuştur. Projenin birinci öncelikli performans metriği olan F1 skoru, hem makro hem ağırlıklı ortalamada 0.87 üzerine ulaşmıştır.

Tablo IV
TEST SETİ PERFORMANSI (SINIF BAZLI VE ORTALAMA)

Sınıf	Prec.	Recall	F1	n
Açık Tekerlekli	1.0000	1.0000	1.0000	78
Van	0.9541	0.9905	0.9720	105
Micro	0.9444	0.9444	0.9444	18
Pick-up	0.9574	0.8333	0.8911	108
SUV	0.8438	0.8710	0.8571	124
Sedan	0.6828	0.9900	0.8082	100
Hatchback	0.9385	0.6289	0.7531	97
Station Wagon	0.8636	0.6552	0.7451	29
Macro avg	0.8981	0.8642	0.8714	659
Weighted avg	0.8916	0.8741	0.8726	659
Accuracy	0.8741			

D. Sınıf Bazlı Analiz

Açık Tekerlekli (F1=1.0000): Mükemmel ayırım. F1 araçlarının mimari olarak diğer tüm araç türlerinden radikal şekilde farklı (kapalı gövdesizlik, açık tekerlekler, kanat yapıları) olması, modelin bu sınıfı hatasız ayırt edebilmesini açıklamaktadır.

Van (F1=0.9720) ve Micro (F1=0.9444): Yüksek performans. Van sınıfı bol veriye sahip (1050 görsel); Micro ise az veriye rağmen sınıf ağırlıklandırması (4.48 ağırlık) sayesinde iyi sonuç vermiştir.


Pick-up (F1=0.8911), SUV (F1=0.8571): Kabul edilebilir seviyede. Modern bazı pick-up modellerinin SUV'ye benzer estetik tasarımları, ufak çapraz karıştırmalara yol açmıştır.

Sedan (F1=0.8082): İlginç bir profil sergiler; recall %99 ama precision %68. Yani model "sedan" kategorisini çok cömert kullanmıştır; özellikle bazı hatchback'leri sedan olarak etiketleme eğilimindedir.

Hatchback (F1=0.7531) ve Station Wagon (F1=0.7451): En zayıf performans. Hatchback'lerin %31'i sedan olarak, station wagon'ların %17'si yine sedan olarak yanlış sınıflandırılmıştır. Bu üç sınıfın fiziksel olarak birbirinin uzantısı şeklinde (sedan ↔ hatchback ↔ station wagon) olduğu düşünülürse, bu tip karışıklığın literatürde de yaygın olduğu söylenebilir [1]. Station Wagon için ek olarak veri yetersizliği (sadece 291 görsel) de bir faktördür.

E. Karışıklık Matrisi

Şekil 3, normalize edilmiş 8×8 karışıklık matrisini göstermektedir. Diagonalin baskın olması modelin genel olarak doğru çalıştığını gösterir; ana karışıklıklar diagonal dışı belirli hücrelerde toplanmıştır: HATCHBACK→SEDAN: 0.31 (en büyük), STATION_WAGON→SEDAN: 0.17, PICK_UP→SUV: 0.13, SUV→SEDAN: 0.09.



Şekil 3. Test seti üzerinde normalize edilmiş 8×8 karışıklık matrisi. Diagonal baskınlığı modelin doğruluğunu, satır dışı yüksek değerler ise sınıflar arası karışıklığı gösterir.

F. Çıkarım Hızı ve Model Boyutu

Çıkarım süresi iki şekilde ölçülmüştür. **Soğuk başlangıç** (model GPU'ya ilk defa taşınıyor): ~ 4145 ms; bu yalnızca arayüz açıldıktan sonraki ilk tahmin için geçerlidir. **Sıcak çıkarım** (GPU önbelleği hazır): **62 ms**; ikinci ve sonraki tüm tahminlerde bu seviye korunur ve kullanıcı için anlık (real-time) bir deneyim sağlar. Kaydedilmiş model dosyasının boyutu ~ 20 MB olup proje şartı olan 95 MB sınırının çok altındadır.

VI. WEB ARAYÜZÜ

Eğitilen model, **Streamlit** kütüphanesi ile geliştirilmiş bir web arayüzü üzerinden canlı tahmin yapabilmektedir. Streamlit, Python geliştirme deneyimini koruyarak hızlı arayüz prototipleme sağlar; bu proje için ideal bir tercihtir.

A. Mimari

Arayüz, modeli sadece bir kere yükleyip session boyunca ön belleğe alan bir Tahminleyici sınıfı etrafında inşa edilmiştir. Bu sayede her buton tıklamasında model yeniden yüklenmez ve çıkarım süreleri düşük kalır. Çıkarım fonksiyonu hem arayüz tarafından hem de harici test scripti tarafından doğrudan içe aktarılarak kullanılabilir.

B. Bileşenler

Arayüz, proje şartnamesinde belirtilen dört ana bileşeni içerir:

- 1) **Görsel Yükleme Alanı:** Sürükle-bırak destekli, JPG/PNG/WEBP formatlarını kabul eden bir dosya yükleyicisi. Yüklenen görselin önizlemesi anında sol sütunda gösterilir.
- 2) **Tahmin Yap Butonu:** Birincil stilde belirgin bir buton; tıklandığında tahmin akışı tetiklenir.
- 3) **Tahmin Sonucu Çıktısı:** Sağ sütunda, mavi arka planlı büyük bir kart içinde tahmin edilen sınıf adı ve güven yüzdesi sergilenir. Altında çıkarım süresi (ms cinsinden) gösterilir.
- 4) **Olasılık Dağılımı:** 8 sınıfın hepsi için softmax olasılıkları, ilerleme çubukları hâlinde görselleştirilir.

Sol kenar çubuğunda model meta bilgisi (mimari adı, sınıf sayısı, giriş boyutu, kullanılan cihaz) sergilenmektedir.

C. Performans Doğrulaması

Arayüz RTX 2060 üzerinde test edilmiştir. Doğrulayıcı tahminler:

- Bir Dodge Caliber Wagon görseli: model %76 Hatchback, %10 Station Wagon tahmin etti — sınır vakaya doğru en güçlü tahmin.
- Bir Ferrari F1 görseli: %90.65 güvenle Açık Tekerlekli (F1) sınıfı; çıkarım süresi 62 ms.

VII. SONUÇ VE GELECEK ÇALIŞMALAR

Bu çalışmada, sekiz sınıflı araba gövde tipi sınıflandırma problemi için EfficientNet-B0 tabanlı, transfer öğrenmeli bir derin öğrenme modeli geliştirilmiştir. Kaggle ve web kaynaklarından derlenen 6628 görsel ile özelleştirilmiş bir veri seti oluşturulmuş; test setinde **0.8714** makro F1 skoru ve **%87.41** doğruluk elde edilmiştir. Streamlit tabanlı web arayüzü ile model, sıcak çıkarımda ortalama 62 ms gibi düşük bir sürede canlı tahmin yapabilmektedir.

Açık Tekerlekli, Van ve Micro sınıflarında neredeyse mükemmel performans elde edilmiştir. Hatchback, Sedan ve Station Wagon sınıfları arasındaki yapısal benzerlik, bu üç sınıf arası karışıklığa yol açmıştır. Bu durum literatürde belgelenmiş bir gerçektir ve insan etiketleyicilerin bile zorlandığı bir sınırdır.

Gelecek çalışmalar için önerilen yönler:

- **Daha fazla veri:** Micro ve Station Wagon sınıfları için ek veri toplanması, sınıf dengesini iyileştirip performansı artırabilir.
- **Daha büyük omurgalar:** EfficientNet-B3 veya ConvNeXt-Tiny gibi daha geniş kapasiteli modellerle karşılaştırma yapılması.
- **Transformer mimariler:** Vision Transformer (ViT) [5] veya Swin Transformer [6] gibi öz-dikkat tabanlı mimarilerle ince taneli sınıflandırmada karşılaştırmalı deney.
- **Test-Time Augmentation (TTA):** Test sırasında birkaç augmentation versiyonu üzerinde tahmin yapıp ortalama almak, sınır vakalarda ek doğruluk sağlayabilir.
- **Hard-example mining:** Hatchback-Sedan-Station Wagon üçlüsünde hatalı sınıflandırılan örneklerle odaklı ikinci bir eğitim aşaması (curriculum learning).

KAYNAKLAR

- [1] J. Krause, M. Stark, J. Deng, and L. Fei-Fei, "3D Object Representations for Fine-Grained Categorization," in *Proc. IEEE ICCV*, 2013, pp. 554–561.
- [2] M. Tan and Q. Le, "EfficientNet: Rethinking Model Scaling for Convolutional Neural Networks," in *Proc. ICML*, vol. 97, 2019, pp. 6105–6114.
- [3] C. Szegedy, V. Vanhoucke, S. Ioffe, J. Shlens, and Z. Wojna, "Rethinking the Inception Architecture for Computer Vision," in *Proc. IEEE CVPR*, 2016, pp. 2818–2826.
- [4] I. Loshchilov and F. Hutter, "Decoupled Weight Decay Regularization," in *Proc. ICLR*, 2019.
- [5] A. Dosovitskiy *et al.*, "An Image is Worth 16x16 Words: Transformers for Image Recognition at Scale," in *Proc. ICLR*, 2021.
- [6] Z. Liu *et al.*, "Swin Transformer: Hierarchical Vision Transformer using Shifted Windows," in *Proc. IEEE/CVF ICCV*, 2021, pp. 10012–10022.
- [7] DA_VINCL_CODE, "Car Body Types Images Dataset," Kaggle, 2022. [Online]. Available: <https://www.kaggle.com/datasets/ademboukhris/cars-body-type-cropped>
- [8] M. Mahurkar, "Stanford Car Body Type Data," Kaggle, 2022. [Online]. Available: <https://www.kaggle.com/datasets/mayurmahurkar/stanford-car-body-type-data>
- [9] L. Mishra, "F1 Image Classification Updated," Kaggle, 2023. [Online]. Available: <https://www.kaggle.com/datasets/loveymishra/f1-image-classification-updated>